

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ  
РОССИЙСКОЙ ФЕДЕРАЦИИ  
федеральное государственное автономное образовательное учреждение  
высшего образования «Санкт-Петербургский политехнический  
университет Петра Великого»

Институт компьютерных наук и кибербезопасности

Высшая школа технологий искусственного интеллекта

Направление: 02.03.01 «Математика и компьютерные науки»

Отчет о выполнении курсовой работы  
«Генератор диалогов»  
по дисциплине «Функциональное программирование»  
Вариант 26

Студент,  
группы 5130201/30101

\_\_\_\_\_ Мелещенко С.И.

Преподаватель

\_\_\_\_\_ Моторин Д.Е.

«\_\_\_\_\_» \_\_\_\_\_ 2025г.

Санкт-Петербург, 2025

# Содержание

<b>Введение</b>	<b>4</b>
<b>1 Постановка задачи</b>	<b>5</b>
<b>2 Техническое задание</b>	<b>7</b>
<b>3 Часть 1</b>	<b>10</b>
3.1 Модуль GRAPH.HS . . . . .	10
3.1.1 Определение типов данных . . . . .	10
3.1.2 Построение графа и операции удаления . . . . .	10
3.1.3 Поиск в ширину . . . . .	12
3.1.4 Двухнаправленный поиск в ширину . . . . .	13
3.2 Модуль PERMUTATIONMAP.HS . . . . .	15
3.3 Модуль LADDER.HS . . . . .	17
<b>4 Часть 2</b>	<b>19</b>
4.1 Главный модуль Main . . . . .	19
4.1.1 Модель данных . . . . .	19
4.1.2 Главная функция и основной цикл . . . . .	19
4.1.3 Загрузка и построение моделей . . . . .	20
4.1.4 Генерация продолжения предложения . . . . .	21
4.1.5 Диалог между моделями . . . . .	23
4.1.6 Вспомогательные функции . . . . .	24
4.2 Модуль LIB.HS . . . . .	24
4.2.1 Определение типов данных . . . . .	24
4.2.2 Предобработка текста . . . . .	25
4.2.3 Построение N-граммной модели . . . . .	26
4.2.4 Генерация текста . . . . .	28
4.2.5 Работа с ключами модели . . . . .	29
4.2.6 Сохранение и загрузка модели . . . . .	30
<b>5 Результаты работы</b>	<b>31</b>
<b>6 Заключение</b>	<b>36</b>
<b>Список использованной литературы</b>	<b>37</b>

Приложение. Часть 1. Полный код программы	38
Приложение. Часть 2. Полный код программы	48

# Введение

Игра в лестницы — это увлекательное упражнение, требующее от игроков (может участвовать любое количество) глубоких знаний словарного запаса. Игроки начинают с двух слов одинаковой длины. Одно из них можно считать началом, другое — концом. Задача состоит в том, чтобы найти цепочку других слов, связывающую начальное слово с конечным, где каждая соседняя пара слов отличается одной буквой. Это означает, что игрок начинает со слова, меняет одну букву, чтобы получить новое слово, и продолжает эти преобразования, пока не будет построена полная цепочка от начала до конца. Если в игре участвуют несколько игроков, выигрывает тот, у кого цепочка короче. Вот пример: cat → sat → sag → dag → dog.

Мы разрешим игроку не только менять одну букву, но и добавлять совершенно новую букву, удалять букву, а также произвольно переставлять буквы. Это изменение делает игру гораздо интереснее, поскольку теперь можно находить пути между словами разной длины. С этими правилами можно найти решение для слов find и solution (например, find → fins → ions → loins → tonsil → lotions → solution).

N-грамма — это просто последовательность из  $n$  элементов (звуков, слогов, слов или символов), идущих в каком-то тексте подряд. На практике чаще имеют в виду ряд слов (реже — символов). Последовательность из двух элементов называют биграмма, из трёх элементов — триграмма.

Диалог - последовательность взаимосвязанных речевых актов не менее двух участников, каждый из которых попеременно становится то говорящим, то адресатом речи.

# 1 Постановка задачи

Задание приведено ниже [Рис. 1]:

Курсовая работа. Генератор диалогов (№ 26)

Часть 1. Воспроизвести решение задачи, описанной и реализованной в главах 5 и 6 книги «Изучаем Haskell на примерах» Филиппа Хагенлохера.

Часть 2. Расширить проект из части 1, сохранив качество кода. Цель – написать синтаксический анализатор и генератор текста по заданному слову или сочетанию слов. Задачи:

- разработать синтаксический анализатор текстовых файлов. Использовать следующие правила для анализа: слова состоят только из букв, предложения состоят только из слов, предложения разделяются стандартными знаками препинания;
- составить модель N-грамм из слов ( $N = 4$ ) на основе текста, разбитого на предложения. Ключами могут быть: одно, два или три слова. Значениями являются уникальные продолжения ключей до размера N-граммы (т.е. одно, два или три слова, но суммарное количество слов в ключе и значении  $\leq 4$ ) и вероятность продолжения для данного сочетания. Вероятность продолжения соответствует частоте упоминания данной комбинации в исходном тексте. Пользователь должен иметь возможность сохранить словарь в файл. Предложите тривиальные тестовые данные для проверки работы функций и модели;
- реализовать запрос пользователя к модели N-грамм для продолжения предложения. Запрос организуется следующим образом: пользователь вводит одно, два или три слова, программа продолжает предложение с учетом вероятности. Длина предложения генерируется случайно, но не длиннее самого длинного предложения в исходном тексте;

- организуйте диалог двух различных N-грамм моделей созданных на двух разных текстах. Каждый текст должен быть не короче 100 000 слов. Пользователь задает начальное слово и продолжительность диалога. Каждая модель основывается на последнем слове, паре или тройке из предложения оппонента (если такого ключа нет в словаре модели, то она проходит предложение от конца к началу пока не попадет подходящее слово, в противном случае сгенерировать случайное предложение и пометить его восклицательным знаком в начале);
- организовать взаимодействие пользователя с программой. Пользователь может: создать модель N-грамм по задаваемому файлу; запросить продолжение предложения по вводимому слову; запросить диалог двух моделей; сохранить словарь существующей модели.

Добавить обработку ошибок и некорректного поведения пользователя.

Создать 2 проекта в stack для части 1 и части 2 соответственно. Подготовить исходные данные. Написать отчет о проделанной работе.

Рис. 1. Задание

Цель работы: разработать программный модуль синтаксического анализатора и генератора текста на основе N-граммных моделей для автоматической обработки текстовых данных и генерации текстовых про-

должений с учетом вероятностных характеристик исходного текста и интерактивную среду для генерации текста и диалога между двумя различными текстовыми моделями.

Задачи.

1. Разработать синтаксический анализатор текстовых файлов, осуществляющий разбиение текста на предложения по стандартным знакам препинания, выделение слов, состоящих только из буквенных символов, очистку текста от некорректных символов и цифр.

2. Реализовать построение N-граммной модели ( $N=4$ ) на основе проанализированного текста.

3. Создать генератор текста, обеспечивающий обработку пользовательского запроса, генерацию продолжения с учетом вероятностной модели, случайное определение длины предложения в пределах максимальной длины исходных предложений.

4. Реализовать механизм диалога между двумя различными N-граммными моделями, где каждая модель генерирует реплику на основе последних слов оппонента.

5. Разработать взаимодействие пользователя с программой.

6. Обеспечить корректную обработку ошибок и некорректного ввода.

7. Разработать тестовый набор данных для проверки и протестировать.

## 2 Техническое задание

### 1. Общие сведения

1.1. Наименование программы: «Синтаксический анализатор и генератор текста по заданному слову или сочетанию слов».

1.2. Основание для разработки: учебный проект.

1.3. Назначение программы: обработка текстовых данных, построение N-граммных моделей и генерация текстовых продолжений с учетом вероятности.

### 2. Функциональные требования

#### 2.1. Синтаксический анализ текста

- Программа должна обрабатывать текстовые файлы.
- Названия файла для считывания вводит пользователь.
- Предложения разделяются стандартными знаками препинания: «.», «!», «?».
- Предложения состоят из слов, разделенных « » (пробел), « - », «:», «; », «,- ».

#### 2.2. Построение N-граммной модели

- Модель строится на основе текста.
- Параметр  $N = 4$ .
- Ключи модели: 1-3 слова.
- Значения модели - уникальные продолжения ключей до размера N-граммы. Вероятность продолжения рассчитывается как количество упоминаний комбинации в исходном тексте (ключи + значения) деленое на количество упоминаний ключа в исходном тексте.

- Модель сохраняется в файл .

#### 2.3. Генерация текста

- Пользователь вводит начальную последовательность слов (1-3 слова).
- Программа генерирует продолжение с учетом вероятностей из модели.
- Длина предложения - случайное значение, не превышающее длину самого длинного предложения в исходном тексте.
- Критерий остановки генерации - достигнута максимальная длина

предложения.

#### 2.4. Диалог двух N-граммных моделей

- Пользователь должен иметь возможность инициировать диалог между двумя моделями.

- Пользователь задает начальное слово-триггер и максимальное количество реплик в диалоге.

- Каждая модель, основываясь на последней сгенерированной реплике оппонента, должна извлечь ключ из реплики оппонента. Если для извлеченного ключа (1-3 слова) в словаре модели есть продолжения, сгенерировать ответ на его основе. Иначе сгенерировать случайное предложение, отметив его восклицательным знаком в начале.

#### 2.5. Взаимодействие с пользователем (Интерактивный режим)

- Создать/Загрузить модель - задать имя файла с текстом.

- Сгенерировать продолжение - запрашиваем у пользователя ключ (1-3 слова) и выводим сгенерированное продолжение.

- Запустить диалог - запросить у пользователя две ранее загруженные модели, начальное слово и продолжительность диалога. Отобразить сгенерированный диалог.

- Сохранить текущую активную N-граммную модель в файл для последующей загрузки.

### 3. Нефункциональные требования

#### 3.1. Производительность

- Обработка текстовых файлов объемом до 10 МБ.

- Время построения модели не более 20 секунд.

#### 3.2. Обработка ошибок

- Обработка ситуации, когда файл с текстом не существует.

- Защита от ввода пользователем неверного типа данных, недопустимого значения при выборе пункта в меню.

### 4. Условия испытаний

#### 4.1. Проверка корректности синтаксического анализа

- Разбиение текста на предложения и слова.

- Игнорирование знаков препинания.

#### 4.2. Проверка построения N-грамм



- Соответствие ключей и значений модели исходному тексту.
- Корректность расчета вероятностей.

#### 4.3. Проверка генерации текста

- Соответствие сгенерированного текста вероятностной модели.
- Соблюдение ограничений на длину предложения.

#### 4.4. Проверка механизма диалога

- Корректность выбора ключа для генерации ответа на реплику оппонента.

- При отсутствии определенного ключа поиск ключа меньшей длины и генерация случайного предложения при его отсутствии.

- Соблюдение заданной пользователем длины диалога.

### **5. Стадии разработки**

- 1) Реализация синтаксического анализатора текста;
- 2) построение N-граммной модели и расчет вероятностей;
- 3) реализация генератора текста;
- 4) реализация механизма диалога двух моделей;
- 5) разработка интерактивного пользовательского интерфейса;
- 6) интеграция всех модулей и отладка взаимодействия;
- 4) тестирование на различных данных;
- 5) документирование кода.

## 3 Часть 1

### 3.1 Модуль GRAPH.HS

#### 3.1.1 Определение типов данных

Определены базовые типы и операции для работы с ориентированным графом.

Листинг 1. Определение типов данных

```
1 type DiGraph a = M.HashMap a [a]
2 empty :: DiGraph a
3 empty = M.empty
4 addNode :: (Hashable a, Eq a) => a -> DiGraph a -> DiGraph a
5 addNode =
6     M.alter
7     ( \mNodes ->
8         case mNodes of
9             Nothing -> Just []
10            value -> value
11     )
12 addEdge :: (Hashable a, Eq a) => (a, a) -> DiGraph a -> DiGraph
13         a
14 addEdge (node, child) = M.alter insertEdge node
15     where
16         insertEdge Nothing = Just [child]
17         insertEdge (Just nodes) = Just (L.nub (child : nodes))
```

type DiGraph - тип ориентированного графа. HashMap, где ключ - вершина, значение - список смежных вершин.

empty - создание пустого графа.

addNode - добавление вершины в граф. Если вершина уже существует, оставляет без изменений, если вершины нет, создаем с пустым списком смежности.

addEdge - добавление ориентированного ребра (from, to). Убирает дубликаты в списке смежности. Если узла нет, создаем с одним ребенком, иначе добавляем и убираем дубликаты.

#### 3.1.2 Построение графа и операции удаления

Ниже приведены функции для построения графа и модификации его структуры.

## Листинг 2. Построение графа

```
1 addEdges :: (Hashable a, Eq a) => [(a, a)] -> DiGraph a ->
  DiGraph a
2 addEdges [] graph = graph
3 addEdges (edge : edges) graph = addEdge edge (addEdges edges
  graph)
4 buildDiGraph :: (Hashable a, Eq a) => [(a, [a])] -> DiGraph a
5 buildDiGraph nodes = go nodes M.empty
6   where
7     go [] graph = graph
8     go ((key, value) : xs) graph = M.insert key value (go xs
  graph)
9 children :: (Hashable a, Eq a) => a -> DiGraph a -> [a]
10 children = M.findWithDefault []
11 deleteNode :: (Hashable a, Eq a) => a -> DiGraph a -> DiGraph a
12 deleteNode = M.delete
```

addEdges - добавление нескольких ребер в граф. Базовый случай - пустой список ребер. Используется рекурсивное добавление.

buildDiGraph - построение графа из списка (вершина, список детей). Базовый случай - пустой список. Используется рекурсивное построение.

children - получение списка дочерних вершин для заданной вершины. Возвращает пустой список, если вершины нет.

## Листинг 3. Операции удаления

```
1 deleteNode :: (Hashable a, Eq a) => a -> DiGraph a -> DiGraph a
2 deleteNode = M.delete
3 deleteNodes :: (Hashable a, Eq a) => [a] -> DiGraph a -> DiGraph
  a
4 deleteNodes [] graph = graph
5 deleteNodes (x : xs) graph = M.delete x (deleteNodes xs graph)
6 deleteEdge :: (Hashable a, Eq a) => (a, a) -> DiGraph a ->
  DiGraph a
7 deleteEdge (node, child) =
8   M.alter
9     ( \mNodes ->
10       case mNodes of
11         Nothing -> Just []
12         Just nodes -> Just (L.delete child nodes)
13     )
14   node
```

deleteNode - удаление вершины из графа.

deleteEdge - удаление ориентированного ребра (from, to). Если узла нет, возвращаем пустой список, иначе даляем ребенка из списка смеж-

НОСТИ.

### 3.1.3 Поиск в ширину

Реализован алгоритм поиска в ширину с восстановлением пути.

Листинг 4. Поиск в ширину 1

```
1 type SearchState a = ([a], DiGraph a, DiGraph a)
2 data SearchResult a = Unsuccessful | Successful (DiGraph a)
3 bfsSearch :: forall a. (Hashable a, Eq a) => DiGraph a -> a -> a
  -> Maybe [a]
4 bfsSearch graph start end
5   | start == end = Just [start]
6   | otherwise =
7       case bfsSearch' ([start], graph, empty) of
8         Successful preds -> Just (findSolution preds) -
9   where
10     findSolution :: DiGraph a -> [a]
11     findSolution g = L.reverse (go end)
12     where
13       go x =
14         case children x g of
15           [] -> [x]
16           (v : _) -> x : go v
```

SearchState - состояние поиска - текущий фронт, граф оставшихся вершин, граф предшествования.

SearchResult - результат поиска: неудача или успех с графом предшествования.

bfsSearch - поиск в ширину от start до end. Возвращаем начальную вершину, если начальная и конечная вершины совпадают. Если успех, то восстанавливаем путь, иначе Nothing.

findSolution - восстановление пути по графу предшествования. Если дошли до начала пути, то [x], иначе рекурсивно идем к началу.

Листинг 5. Поиск в ширину 2

```
1 addMultiplePredecessors :: [(a, [a])] -> DiGraph a ->
  DiGraph a
2 addMultiplePredecessors [] g = g
3 addMultiplePredecessors ((n, ch) : xs) g =
4   addMultiplePredecessors xs (go n ch g)
5   where
6     go n [] g = g
7     go n (x : xs) g = go n xs (addEdge (x, n) g)
```

```

8   bfsSearch' :: SearchState a -> SearchResult a
9   bfsSearch' ([], _, preds) = Unsuccessful
10  bfsSearch' (frontier, g, preds) =
11      let g' = deleteNodes frontier g
12          ch = L.map (\n -> (n, L.filter ('M.member' g') (
13              children n g))) frontier
14          frontier' = L.concatMap snd ch
15          preds' = addMultiplePredecessors ch preds
16      in if end 'L.elem' frontier'
17          then Successful preds'
18          else bfsSearch' (frontier', g', preds')

```

addMultiplePredecessors - добавление нескольких предшественников в граф предшествования.

bfsSearch' - один шаг BFS. Если фронт пуст - неудача. Иначе удаляем обработанные вершины и для каждой вершины во фронте находим детей, которые еще в графе. Новый фронт - все дети, обновляем граф предшествования. Успех, если нашли конечную вершину, иначе продолжаем поиск.

### 3.1.4 Двухнаправленный поиск в ширину

Двухнаправленный поиск для повышения эффективности на больших графах.

Листинг 6. Двухнаправленный поиск в ширину 1

```

1 type BiSearchState a = (SearchState a, SearchState a)
2 biBfsSearch :: forall a. (Hashable a, Eq a) => DiGraph a -> a ->
3   a -> Maybe [a]
4 biBfsSearch graph start end
5   | start == end = Just [start]
6   | otherwise =
7       let fState = ([start], graph, empty)
8           bState = ([end], graph, empty)
9       in biBfsSearch' (fState, bState)
10 where
11   findSolution :: DiGraph a -> a -> [a]
12   findSolution g = go
13   where
14       go x =
15           case children x g of
16             [] -> [x]
17             (v : _) -> x : go v

```

BiSearchState - состояние для двунаправленного поиска (прямой и обратный поиск).

biBfsSearch - двунаправленный поиск в ширину. Just [start], если начальная и конечная вершины совпадают. fState - прямой поиск от start, bState - обратный.

findSolution - восстановление пути из графа предшествования.

Листинг 7. Двунаправленный поиск в ширину 2

```

1  checkOverlap :: BiSearchState a -> Maybe [a]
2  checkOverlap ((fFrontier', _, fPreds'), (bFrontier', _,
   bPreds')) =
3      let getSolution x =
4          let fPath = findSolution fPreds' x
5              bPath = findSolution bPreds' x
6              in L.reverse fPath ++ L.tail bPath
7          overlaps = L.filter ('M.member' bPreds') fFrontier'
8          solutions = L.sortOn L.length (L.map getSolution
9              overlaps)
10         then Nothing
11         else Just $ L.head solutions
12
13 checkSolution :: SearchState a -> a -> Maybe [a]
14 checkSolution (frontier, _, preds) node
15     | node 'L.elem' frontier = Just (findSolution preds node)
16     | otherwise = Nothing

```

checkOverlap - проверка пересечения фронтов прямого и обратного поиска. Объединяем пути и смотрим пересечения фронтов. Сортируем по длине. Если нет решений, то Nothing, иначе берем кратчайший путь.

checkSolution - проверка достижения целевой вершины в одном направлении.

Листинг 8. Двунаправленный поиск в ширину 3

```

1  biBfsSearch' :: BiSearchState a -> Maybe [a]
2  biBfsSearch' state@(fState@(fFrontier, _, _), bState@(
   bFrontier, _, _))
3      | L.null fFrontier && L.null bFrontier = Nothing
4      | isJust fSol = fmap L.reverse fSol
5      | isJust bSol = bSol
6      | isJust overlapSol = overlapSol
7      | otherwise = biBfsSearch' biState'
8  where
9      fSol = checkSolution fState end
10     bSol = checkSolution bState start
11     overlapSol = checkOverlap state

```

```

12     fState' = bfsSearchStep fState
13     bState' = bfsSearchStep bState
14     biState' = (fState', bState')

```

biBfsSearch' - основной цикл двунаправленного поиска. Nothing, если оба фронта пусты. isJust fSol = fmap L.reverse fSol - найден путь в прямом направлении, isJust bSol = bSol - найден путь в обратном направлении. isJust overlapSol = overlapSol - найдено пересечение. Иначе продолжаем поиск.

#### Листинг 9. Двунаправленный поиск в ширину 4

```

1  bfsSearchStep :: SearchState a -> SearchState a
2  bfsSearchStep (frontier, g, preds) =
3      let g' = deleteNodes frontier g
4          ch = L.map (\n -> (n, L.filter ('M.member' g') (
5              children n g))) frontier
6          frontier' = L.concatMap snd ch
7          preds' = addMultiplePredecessors ch preds
8      in (frontier', g', preds')
9  addMultiplePredecessors :: [(a, [a])] -> DiGraph a ->
10     DiGraph a
11  addMultiplePredecessors [] g = g
12  addMultiplePredecessors ((n, ch) : xs) g =
13      addMultiplePredecessors xs (go n ch g)
14  where
15      go n [] g = g
16      go n (x : xs) g = go n xs (addEdge (x, n) g)

```

bfsSearchStep - один шаг BFS (аналогично bfsSearch').

addMultiplePredecessors - добавление нескольких предшественников.

## 3.2 Модуль PERMUTATIONMAP.HS

Карта перестановок для эффективного поиска слов с одинаковым набором букв.

#### Листинг 10. Модуль 1

```

1 type PermutationMap = M.HashMap BS.ByteString [BS.ByteString]
2 empty :: PermutationMap
3 empty = M.empty
4 member :: BS.ByteString -> PermutationMap -> Bool
5 member key = M.member (BS.sort key)
6 alter ::
7     ( Maybe [BS.ByteString] ->
8       Maybe [BS.ByteString]

```

```

9   ) ->
10  BS.ByteString ->
11  PermutationMap ->
12  PermutationMap
13  alter f key = M.alter f (BS.sort key)
14  delete :: BS.ByteString -> PermutationMap -> PermutationMap
15  delete key = M.delete (BS.sort key)
16  insert :: BS.ByteString -> [BS.ByteString] -> PermutationMap ->
    PermutationMap
17  insert key = M.insert (BS.sort key)
18  lookup :: BS.ByteString -> PermutationMap -> Maybe [BS.
    ByteString]
19  lookup key = M.lookup (BS.sort key)

```

PermutationMap - карта перестановок - ключ - отсортированная версия слова. Значение - список исходных слов с такими же буквами.

empty - пустая карта перестановок.

member - проверка наличия слова в карте.

alter - модификация значения в карте.

delete - удаление слова из карты.

insert - вставка значения в карту.

lookup - поиск значения в карте.

#### Листинг 11. Модуль 2

```

1  findWithDefault :: [BS.ByteString] -> BS.ByteString ->
    PermutationMap -> [BS.ByteString]
2  findWithDefault defaultValue key map =
3  fromMaybe [] (PermutationMap.lookup key map)
4  createPermutationMap :: [BS.ByteString] -> PermutationMap
5  createPermutationMap = go empty
6  where
7  go permMap [] = permMap
8  go permMap (x : xs) = go (insertPermutation x permMap) xs
9  insertPermutation word = alter (insertList word) word
10 insertList word Nothing = Just [word]
11 insertList word (Just words) = Just $ word : words

```

findWithDefault - поиск со значением по умолчанию. Если не найдено, возвращаем пустой список.

createPermutationMap - создание карты перестановок из словаря. Группирует слова по их отсортированным версиям. Базовый случай - пустой список, иначе рекурсивная обработка.

insertPermutation - вставка одного слова в карту перестановок.



insertList - функция для вставки в список значений. Если ключа нет, создаем новый список, иначе добавляем к существующему.

### 3.3 Модуль LADDER.HS

Модуль для работы со словными цепочками, использует графовые алгоритмы для поиска путей.

Листинг 12. Модуль 1

```
1 module Ladder
2   ( Dictionary ,
3     readDictionary ,
4     ladderSolve ,
5   )
6 where
7 type Dictionary = [BS.ByteString]
8 readDictionary :: FilePath -> IO Dictionary
9 readDictionary filepath = do
10   dictionaryContent <- C.readFile filepath
11   let lines = C.lines dictionaryContent
12       words = L.map (C.filter ('L.elem' ['a' .. 'z'])) lines
13   return words
14 delete :: Char -> BS.ByteString -> BS.ByteString
15 delete ch string = case C.uncons string of
16   Just (x, xs) -> if ch == x then xs else C.cons x (delete ch xs)
17   Nothing -> C.empty
18 computeCandidates :: PM.PermutationMap -> BS.ByteString -> [BS.ByteString]
19 computeCandidates map word =
20   let candidates = modified ++ removed ++ added ++ [word]
21       perms = L.concatMap (\x -> PM.findWithDefault [] x map)
22           candidates
23   in L.filter (/= word) (L.nub perms)
24 where
25   added = [C.cons x word | x <- ['a' .. 'z']]
26   removed = [delete x word | x <- C.unpack word]
27   modified = [C.cons x (delete y word) | x <- ['a' .. 'z'], y
28     <- C.unpack word, x /= y]
```

Dictionary - список слов в виде ByteString.

readDictionary - чтение словаря из файла. Фильтрует только буквы a-z, игнорируя другие символы. Сначала читаем весь файл, разбиваем на строки и оставляем только буквы.

delete - удаление первого вхождения символа из строки.

computeCandidates - вычисление соседних слов в словной цепочке. Соседние слова отличаются одной операцией - добавление, удаление или замена буквы.

#### Листинг 13. Модуль 2

```
1 mkLadderGraph :: Dictionary -> G.DiGraph BS.ByteString
2 mkLadderGraph dict = G.buildDiGraph nodes
3   where
4     map = PM.createPermutationMap dict
5     nodes = L.map (\w -> (w, computeCandidates map w)) dict
6 ladderSolve :: Dictionary -> String -> String -> Maybe [BS.
   ByteString]
7 ladderSolve dict start end =
8   let g = mkLadderGraph dict
9   in G.biBfsSearch g (C.pack start) (C.pack end)
```

mkLadderGraph - построение графа словных цепочек. Каждое слово связано с соседями, отличающимися на одну операцию.

ladderSolve - решение задачи поиска словной цепочки. Строит граф и ищет путь между start и end.

## 4 Часть 2

### 4.1 Главный модуль Main

Основной функционал это управление интерфейсом командной строки, обработка пользовательского ввода, загрузка моделей из файлов, запуск диалога между моделями, генерация ответа модели и координация работы всех компонентов.

#### 4.1.1 Модель данных

Позволяет хранить N-граммную модель и ее данные.

Листинг 14. ModelWithInfo

```
1 data ModelWithInfo = ModelWithInfo {  
2     model :: NGramModel,  
3     maxSentenceLength :: Int  
4 } deriving (Show)
```

maxSentenceLength - максимальная длина предложения в тексте.  
deriving (Show) для отображения.

#### 4.1.2 Главная функция и основной цикл

Реализация интерактивного интерфейса с меню.

Листинг 15. main

```
1 main :: IO ()  
2 main = do  
3     TIO.putStrLn "\n 4-GRAM TEXT GENERATOR"  
4     mainLoop Nothing Nothing  
5 mainLoop :: Maybe ModelWithInfo -> Maybe ModelWithInfo -> IO ()  
6 mainLoop currentModel model2 = do  
7     TIO.putStrLn "\n MENU"  
8     TIO.putStrLn "0. Exit"  
9     TIO.putStrLn "1. Load or build main model"  
10    TIO.putStrLn "2. Save the current model to file"  
11    TIO.putStrLn "3. Generate the continuation of the sentence"  
12    TIO.putStrLn "4. Load or build second model for the dialogue"  
13    TIO.putStrLn "5. Dialogue between two models"  
14    TIO.putStrLn $ T.pack $ "\n Current first model: " ++  
    modelStatus currentModel
```

```

15 TIO.putStrLn $ T.pack $ "Current second model: " ++
    modelStatus model2
16 choice <- TIO.getLine
17 case T.unpack choice of

```

Выводится меню программы для пользователя.

currentModel - текущая основная модель.

model2 - вторая модель для диалога.

Отображается статус моделей (загружена или нет). choice принимает пользовательский ввод пункта меню, а затем идет обработка всех возможных вариантов ввода.

### 4.1.3 Загрузка и построение моделей

Функция загружает текстовый файл, считает количество слов, определяет максимальную длину предложений и строит N-граммную модель.

Листинг 16. loadTextModelLoop

```

1 loadTextModelLoop :: Maybe ModelWithInfo -> Maybe ModelWithInfo
  -> IO ()
2 loadTextModelLoop currentModel model2 = do
3   TIO.putStrLn "Enter a file name with text (0 to return):"
4   fileName <- TIO.getLine
5   case fileName of
6     "0" -> mainLoop currentModel model2
7     _ -> do
8       result <- readFileSafe (T.unpack fileName)
9       case result of
10        Left errorMsg -> do
11          TIO.putStrLn $ T.pack errorMsg
12          loadTextModelLoop currentModel model2
13        Right content -> do
14          let sentences = splitText (T.pack content)
15          let wordCount = sum (map length sentences)
16          let maxSentenceLen = if null sentences then
17            0 else maximum (map length sentences)
18          TIO.putStrLn $ "Text loaded. Total words: "
19            'T.append' T.pack (show wordCount)
20          TIO.putStrLn $ "Max sentence length: " 'T.
21            append' T.pack (show maxSentenceLen)
22          let newModel = buildNGramModel sentences 4
23          TIO.putStrLn "Model successfully built!"
24          mainLoop (Just $ ModelWithInfo newModel
25            maxSentenceLen) model2

```

Функция принимает ввод имени файла с текстом. Если ввод это «0», то возвращаемся в меню. Иначе читаем файл. Если при чтении происходит ошибка - отображаем ее, иначе разбиваем текст на предложения, считаем число слов, максимальную длину предложения. Выводим информационные сообщения об успешной загрузке файла, общем количестве слов, максимальной длине предложения. Строим N-граммную модель. Выводим сообщение об успешном построении модели, записываем максимальную длину предложения.

#### 4.1.4 Генерация продолжения предложения

В данной части происходит генерация продолжения с проверкой ограничений длины и обработкой пользовательского ввода.

Листинг 17. Генерация продолжения предложения 1

```

1 "3" -> do
2   case currentModel of
3     Nothing -> do
4       TIO.putStrLn "Build or download the model first!"
5       mainLoop currentModel model2
6     Just modelInfo -> do
7       TIO.putStrLn "Enter starting words (1-3 words, 0 to
8         return):"
9       input <- TIO.getLine
10      when (input /= "0") $ do
11        let wordsList = map T.toLower (T.words input)
12        if length wordsList >= 1 && length wordsList <=
13          3
14        then do
15          let initialLen = length wordsList
16          let maxTotalLen = maxSentenceLength
17            modelInfo
18          if maxTotalLen <= initialLen
19            then do
20              TIO.putStrLn $ T.pack $ "Initial
              words already have " ++ show
              initialLen ++
              " words, but maximum
              sentence length is " ++
              show maxTotalLen ++
              ". Cannot generate
              continuation."
              mainLoop currentModel model2

```

Если пользователь выбрал пункт 3 меню, то начинается работа с ге-

нерацией продолжения. Если не выбрана текущая модель, то выводит сообщение о необходимости загрузить модель (пункт 1 меню) и возвращаемся в меню. Иначе просим пользователя ввести 1-3 слова, либо 0 для возвращения в меню. Получаем ввод. Если ввод «0», то возвращаемся в меню. Если ввод не «0», то приводим ввод к нижнему регистру. Если слов введено менее 1 или более 3х, то выводит сообщение об ошибке ввода и возвращаемся в меню. Иначе считаем количество введенных пользователем слов и инициализируем максимальную длину предложения.

Листинг 18. Генерация продолжения предложения 2

```

1 else do
2     let maxAdditional = maxTotalLen - initialLen
3     randomAdditionalLen <- if maxAdditional > 0
4         then randomRIO (1, maxAdditional)
5         else return 0
6     if randomAdditionalLen <= 0
7         then do
8             TIO.putStrLn "Cannot generate continuation — no
9                 space for additional words."
10            mainLoop currentModel model2
11        else do
12            result <- generateContinuation (model
13                modelInfo) wordsList randomAdditionalLen
14            TIO.putStrLn $ "Generated continuation: " 'T
15                .append' T.unwords result
16            mainLoop currentModel model2
17        else do
18            TIO.putStrLn "Error: Please enter
19                between 1 and 3 words."
20            mainLoop currentModel model2

```

Если введено слов больше, чем длина самого длинного предложения в тексте, то выводим ошибку и возвращаемся в меню. Иначе генерируем случайную длину, проверяя ее на корректность. Затем генерируем продолжение с использованием модели и выводим на экран. Выходим в меню.

### 4.1.5 Диалог между моделями

Реализован механизм диалога, где модели поочередно генерируют реплики на основе предыдущих высказываний.

Листинг 19. Диалог между моделями

```
1 startDialog :: NGramModel -> NGramModel -> [Text] -> Int -> IO
  ()
2 startDialog model1 model2 startWords reps = do
3   TIO.putStrLn "\n START OF DIALOGUE"
4   TIO.putStrLn $ "Starting word: " 'T.append' T.unwords
   startWords
5   dialogLoop model1 model2 startWords reps 0
6
7
8 dialogLoop :: NGramModel -> NGramModel -> [Text] -> Int -> Int
  -> IO ()
9 dialogLoop _ _ _ totalReps currentRep
10  | currentRep >= totalReps = TIO.putStrLn "DIALOGUE ENDED"
11 dialogLoop model1 model2 lastPhrase totalReps currentRep = do
12   let currentModel = if even currentRep then model1 else
   model2
13   let opponentModel = if even currentRep then model2 else
   model1
14   let speaker = if even currentRep then "Model 1" else "Model
   2"
15   response <- generateResponse currentModel lastPhrase
16   TIO.putStrLn $ T.pack speaker 'T.append' ": " 'T.append' T.
   unwords response
17   dialogLoop model1 model2 response totalReps (currentRep + 1)
```

startDialog - запуск диалога между двумя N-граммными моделями.

model1, model2 - модели для диалога.

startWords - начальные слова для диалога.

reps - количество реплик в диалоге.

Выводим сообщение о начале диалога и начальное слово. Вызываем dialogLoop.

dialogLoop - цикл диалога между моделями. Поочередно генерирует реплики для каждой модели.

Если currentRep >= totalReps, то заканчиваем диалог моделей. Далее в коде идет определение текущей модели и ее «собеседника». Если currentRep четное, то текущая модель - model1, иначе - model2. Затем идет генерация ответа на основе последней фразы. Рекурсивно вызыва-

ем для следующей реплики.

### 4.1.6 Вспомогательные функции

Ниже приведены функции для безопасной работы с файлами и пользовательским вводом.

Листинг 20. Вспомогательные функции

```
1 readFileSafe :: FilePath -> IO (Either String String)
2 readFileSafe fileName = catch (readFile fileName >>= return .
  Right) handleError
3 where
4   handleError :: IOException -> IO (Either String String)
5   handleError e = do
6     let errorMsg = "File reading error: " ++ show e
7     return $ Left errorMsg
8
9 safeRead :: String -> Int -> Int
10 safeRead str defaultValue = case readMaybe str of
11   Just n -> n
12   Nothing -> defaultValue
```

`readFileSafe` - безопасное чтение файла с обработкой ошибок ввода-вывода.

`safeRead` - безопасное преобразование строки в число с значением по умолчанию.

## 4.2 Модуль LIB.HS

### 4.2.1 Определение типов данных

Определены типы данных для работы с N-граммами, используется структура `HashMap` для хранения модели.

Листинг 21. Определение типов данных

```
1
2 module Lib (
3   NGramModel,
4   splitText,
5   buildNGramModel,
6   saveModel,
7   loadModel,
8   generateContinuation,
9   getPossibleKeys,
```



```

10     findValidKey ,
11     getRandomKey ,
12     preprocessText
13 ) where
14
15 type NGram = [Text]
16 type NGramModel = HashMap NGram [(NGram, Double)]

```

type NGram - тип для представления N-граммы.

type NGramModel - тип для N-граммной модели.

Ключ - это N-грамма (1-3 слова).

Значение - список возможных продолжений с вероятностями.

## 4.2.2 Предобработка текста

Реализована предобработка текста, включающая очистку, нормализацию и разбиение на предложения.

Листинг 22. Предобработка текста 1

```

1 cleanWord :: Text -> Text
2 cleanWord word =
3     let cleaned = T.toLower $ T.filter validChar word
4     in if isValidCleanedWord cleaned then cleaned else T.empty
5 where
6     validChar c = isAscii c && (isLetter c || c == '\'' || c ==
7         '-')
8     isValidCleanedWord w = not (T.null w) && T.any isLetter w
9
10 splitText :: Text -> [[Text]]
11 splitText text =
12     let preprocessed = preprocessText text
13     sentences = splitSentences preprocessed
14     in filter (not . null) $ map processSentence sentences

```

cleanWord - служит для очистки слова от некорректных символов и приведение к нижнему регистру. Сохраняет апострофы и дефисы внутри слов.

Сначала приводит все к нижнему регистру, затем фильтрует. Проверяем, что слово не пустое.

splitText - разделение текста на предложения и слова, выполняет нормализацию символов и фильтрацию некорректных слов.

Сначала происходит нормализация символов, затем идет разбиение на

предложения (по «.», «!», «?»). Обрабатываем каждое и убираем пустые. Запускаем рекурсию по тексту. Базовый случай - пустой текст. Иначе разбиваем на первое предложение и остаток, отделяем знаки препинания. Если предложение пустое - обрабатываем остаток. Очищаем предложение и добавляем знак препинания, затем обрабатываем остаток.

Листинг 23. Предобработка текста 2

```

1  where
2      splitSentences :: Text -> [Text]
3      splitSentences t
4          | T.null t = []
5          | otherwise =
6              let (sentence, rest) = T.break isSentenceTerminator
7                  t
8                  (punctuation, rest') = T.span
9                      isSentenceTerminator rest
10             in if T.null sentence
11                 then splitSentences rest'
12                 else (cleanSentence sentence 'T.append' T.take 1
13                     punctuation) : splitSentences rest'
14
15 processSentence :: Text -> [Text]
16 processSentence = filter isValidWord . map T.toLowerCase . T.
17     words . T.map normalizeChar

```

processSentence - обработка одного предложения: разбиение на слова, нормализация символов, фильтрация.

### 4.2.3 Построение N-граммной модели

Модель строится путем извлечения всех возможных N-грамм из текста и расчета вероятностей их продолжений.

Листинг 24. Построение N-граммной модели 1

```

1 buildNGramModel :: [[Text]] -> Int -> NGramModel
2 buildNGramModel sentences n =
3     let validSentences = filter (all isValidWord) sentences
4         allNGrams = concatMap (getNGrams n) validSentences
5         grouped = HashMap.fromListWith (++) [(key, [(value, 1)])
6             | (key, value) <- allNGrams]
7     in HashMap.map calculateProbabilities grouped
8 where

```

buildNGramModel - построение N-граммной модели из предложений.  
sentences - список предложений.

n - размер N-граммы (4).

Фильтруем предложения, оставляя только те, где все слова валидны. Для каждого валидного предложения извлекаем все возможные N-граммы, группируем N-граммы по ключам и подсчитываем вероятности. `HashMap.fromListWith (++)` создает `HashMap`, объединяя значения для одинаковых ключей (`key, [(value, 1)]`). При совпадении ключей списки объединяются.

Листинг 25. Построение N-граммной модели 2

```
1  getNGrams :: Int -> [Text] -> [(NGram, NGram)]
2  getNGrams n words =
3      [ (take k context, take (n - k) continuation)
4        | k <- [1..min 3 (length words)] — Ключи длиной 1, 2,
          3 слова
5        , (context, continuation) <- zip (tails words) (drop k (
          tails words))
6        , length context >= k
7        , length continuation >= n - k
8        , length context + length continuation >= n
9        , filterValidNGram (take k context, take (n - k)
          continuation)
10     ]
11
12  calculateProbabilities :: [(NGram, Int)] -> [(NGram, Double)]
13  calculateProbabilities pairs =
14      let total = fromIntegral $ sum (map snd pairs)
15      in [(ngram, fromIntegral count / total) | (ngram, count)
          <- pairs]
```

`getNGrams` - извлечение всех N-грамм из предложения.

`tails words` генерирует все суффиксы предложения, `drop k (tails words)` - суффиксы, начинающиеся с k-го слова, `zip` создает пары (`context, continuation`), где `continuation` начинается через k слов от `context`. В `context` достаточно слов для ключа длины k, в `continuation` достаточно слов для продолжения длины n-k, `length context + length continuation >= n` - общее количество слов достаточно для N-граммы. Затем проверяем, что и ключ и продолжение состоят из валидных слов.

`calculateProbabilities` - расчет вероятностей продолжений для каждого ключа. Вероятность = частота продолжения / общая частота всех продолжений для данного ключа. `fromIntegral` преобразует `Int` в `Double` для деления.

## 4.2.4 Генерация текста

Генерация реализована как рекурсивный процесс выбора следующих слов на основе вероятностей из модели.

Листинг 26. Генерация текста 1

```
1 generateContinuation :: NGramModel -> [Text] -> Int -> IO [Text]
2 generateContinuation model startWords maxLength = do
3   gen <- newStdGen
4   return $ generateEfficient model startWords gen maxLength
5 where
6   generateEfficient :: NGramModel -> [Text] -> StdGen -> Int
7   -> [Text]
8   generateEfficient model currentWords gen maxLength =
9     generateLoop model currentWords gen maxLength
10    currentWords
11 generateLoop :: NGramModel -> [Text] -> StdGen -> Int -> [
12   Text] -> [Text]
13 generateLoop _ _ _ 0 acc = acc
14 generateLoop model currentWords gen remaining acc =
15   let possibleKeys = getPossibleKeys currentWords
16       key = findValidKey model possibleKeys
17   in case key of
18     Nothing -> acc — Не найдено подходящего ключа
19     Just k ->
20       case HashMap.lookup k model of
21         Nothing -> acc
22         Just continuations ->
23           let (choice, newGen) =
24             efficientWeightedRandom continuations
25             gen
26               newWords = acc ++ choice
27               newRemaining = remaining - length
28               choice
29           in if newRemaining <= 0
30             then newWords
31             else generateLoop model (currentWords
32               ++ choice) newGen newRemaining
33               newWords
```

Используется вероятностная модель для выбора следующих слов, каждое следующее слово зависит от предыдущих.

Создаем новый генератор случайных чисел, `generateEfficient` инициализирует рекурсивную генерацию. Начинаем с текущих слов и используем их как начальный аккумулятор.

На каждом шаге пытаемся найти продолжение для текущего кон-

текста и добавляем его к результату, пока не достигнем максимальной длины или не сможем найти подходящее продолжение. Если достигнута максимальная длина - возвращаем накопленный результат, получаем возможные ключи из текущего контекста, ищем первый ключ, который есть в модели. Иначе возвращаем что есть (acc). Если найден валидный ключ в модели, предусматриваем защиту от Nothing. Если Just, то используется взвешенный случайный выбор продолжения.

Листинг 27. Генерация текста 2

```

1  efficientWeightedRandom :: [(NGram, Double)] -> StdGen -> (
    NGram, StdGen)
2  efficientWeightedRandom choices gen =
3      let total = sum (map snd choices)
4          (r, newGen) = randomR (0, total) gen
5          sortedChoices = sortOn (Down . snd) choices
6      in pick sortedChoices r newGen
7  where
8      pick [] _ g = ([], g)
9      pick ((ngram, prob):rest) rVal g
10         | rVal <= prob = (ngram, g)
11         | otherwise = pick rest (rVal - prob) g

```

efficientWeightedRandom - взвешенный случайный выбор на основе вероятностей. Случайное число в диапазоне [0, total].

sortedChoices - более вероятные варианты проверяются первыми. Далее вызывается рекурсивная функция для выбора варианта. Если случайное число попало в интервал этого варианта - выбираем его. Иначе переход к следующему варианту, вычитая пройденную вероятность.

#### 4.2.5 Работа с ключами модели

Функции для работы с ключами модели реализуют стратегию «от самых длинных к самым коротким» ключам.

Листинг 28. Работа с ключами модели

```

1  getPossibleKeys :: [Text] -> [[Text]]
2  getPossibleKeys words =
3      let n = length words
4          key1 = if n >= 1 then [last words] else []
5          key2 = if n >= 2 then drop (n-2) words else []
6          key3 = if n >= 3 then drop (n-3) words else []
7      in filter (not . null) [key3, key2, key1]
8
9  findValidKey :: NGramModel -> [[Text]] -> Maybe [Text]

```

```

10 findValidKey model keys =
11     case filter ('HashMap.member' model) keys of
12         [] -> Nothing
13         (k:_) -> Just k

```

key1 - ключ из последнего слова.

key2 - ключ из двух последних слов.

key3 - ключ из трех последних слов.

Фильтруем пустые ключи и возвращаем в порядке от самых длинных к коротким.

## 4.2.6 Сохранение и загрузка модели

Функции для работы с ключами модели реализуют стратегию «от самых длинных к самым коротким» ключам.

Листинг 29. Сохранение и загрузка модели

```

1 saveModel :: FilePath -> NGramModel -> IO ()
2 saveModel filePath model = withFile filePath WriteMode $ \h ->
3     mapM_ \(k, vs) -> TIO.hPutStrLn h $ T.pack (show k) 'T.
4         append' " => " 'T.append' T.pack (show vs)) (HashMap.
5             toList model)
6
7 loadModel :: FilePath -> IO (Maybe NGramModel)
8 loadModel filePath = do
9     result <- try (TIO.readFile filePath) :: IO (Either
10         SomeException Text)
11     case result of
12         Left _ -> return Nothing
13         Right content ->
14             let lines' = T.lines content
15                 parsed = catMaybes $ map parseLine lines'
16             in return $ if null parsed then Nothing else Just (
17                 HashMap.fromList parsed)

```

saveModel - сохранение N-граммной модели в файл. Каждая строка представляет одну запись модели ключ => список (продолжение, вероятность).

withFile - безопасно открывает и закрывает файл.

loadModel - загрузка N-граммной модели из файла с обработкой исключений.

## 5 Результаты работы

При запуске программы отображается меню [Рис. 2]:

```
4-GRAM TEXT GENERATOR

MENU
0. Exit
1. Load or build main model
2. Save the current model to file
3. Generate the continuation of the sentence
4. Load or build second model for the dialogue
5. Dialogue between two models

Current first model: not loaded
Current second model: not loaded
9
Wrong choice!

MENU
0. Exit
1. Load or build main model
2. Save the current model to file
3. Generate the continuation of the sentence
4. Load or build second model for the dialogue
5. Dialogue between two models

Current first model: not loaded
Current second model: not loaded
```

Рис. 2. Меню

Предусмотрена защита от некорректного пользовательского ввода в каждом пункте и подпункте меню.

Пункт 2 - загрузка модели. Пользователю предлагается выбрать построить модель из файла или загрузить файл с моделью [Рис. 3]:

```
Current first model: not loaded
Current second model: not loaded
1

Loading or building main model
1. Build from a text file
2. Load from model file
0. Return
```

Рис. 3. Загрузка модели

При выборе первого пункта пользователю предлагается ввести название файла [Рис. 4]:

```

1
Enter a file name with text (0 to return):
rerefe
File reading error: rerefe: openFile: does not exist (No such file or directory)
Enter a file name with text (0 to return):
text2.txt
Text loaded. Total words: 203501
Max sentence length: 102
Model successfully built!

```

Рис. 4. Построение модели из файла

Так же предусмотрена обработка отсутствующих файлов.

Загрузка модели из файла выглядит следующим образом [Рис. 5]:

```

Loading or building main model
1. Build from a text file
2. Load from model file
0. Return
2
Enter the file name of the model (0 to return):
df
Model loading error! Please try again.
Enter the file name of the model (0 to return):
d.txt
Model loaded!

```

Рис. 5. Загрузка модели из файла

Пункт 2 меню - сохранение модели в файл [Рис. 6]:

```

Current first model: loaded
Current second model: not loaded
2
Enter a file name to save (0 to return):
d1.txt
Model saved!

```

Рис. 6. Сохранение модели в файл

Модель выглядит следующим образом [Рис. 7]:



```

1 ["i","will","confess"] => [{"something"},1.0]
2 ["younger","dressed"] => [{"literally","in"},1.0]
3 ["his","initiation"] => [{"into","a"},1.0]
4 ["late","he"] => [{"had","never"},0.5],[{"had","often"},0.5]
5 ["some","queen"] => [{"almost","animal"},1.0]
6 ["a","soothing","effect"] => [{"on"},1.0]
7 ["they","had","started"] => [{"were"},1.0]
8 ["thats","all","one"] => [{"might"},1.0]
9 ["was","a","little"] => [{"drunk"},0.2],[{"pocket"},0.2],[{"taken"},0.2],[{"offended"},0.2],[{"the"},0.2]
10 ["that","is","among"] => [{"the"},1.0]
11 ["hey","alyona"] => [{"ivanovna","old"},1.0]
12 ["time","that","the"] => [{"bodice"},1.0]
13 ["moment","on","to"] => [{"his"},1.0]
14 ["got","a","notion"] => [{"in"},1.0]
15 ["petrovitch","indeed","seemed"] => [{"almost"},1.0]
16 ["education","but"] => [{"once","youre"},1.0]
17 ["darker","and","darker"] => [{"as"},1.0]
18 ["has","just","peeped"] => [{"out"},1.0]
19 ["difficult","there","was"] => [{"a"},1.0]
20 ["that","so"] => [{"far","as"},1.0]
21 ["by","a","thrill"] => [{"of"},1.0]
22 ["of","great","physical"] => [{"strength"},1.0]
23 ["about","eight","steps"] => [{"from"},1.0]
24 ["a","poignant","and"] => [{"rebellious"},1.0]
25 ["certainly","can"] => [{"put","up"},1.0]

```

Рис. 7. Модель

Пункт 3 - генерация продолжения. Если введено более 3х слов предусмотрен вывод ошибки [Рис. 8]:

```

Current first model: loaded
Current second model: not loaded
3
Enter starting words (1-3 words, 0 to return):
he was a fool
Error: Please enter between 1 and 3 words.

MENU

```

Рис. 8. Генерация продолжения с некорректным вводом

Ниже приведена успешная генерация продолжения [Рис. 9]:

```

Current first model: loaded
Current second model: not loaded
3
Enter starting words (1-3 words, 0 to return):
he was
Generated continuation: he was frightened bent down

```

Рис. 9. Генерация продолжения

При попытке генерации диалога без второй модели - ошибка [Рис. 10]:

```
Current first model: loaded
Current second model: not loaded
5
First, download both models! (the main and the second)
```

Рис. 10. Попытка генерации диалога без второй модели

Аналогично с пунктом 3 без загрузки основной модели.

Загрузка второй модели аналогична загрузке первой [Рис. 11]:

```
Current first model: loaded
Current second model: not loaded
4

Loading the second model
1. Build from a text file
2. Load from model file
0. Return
1
Enter a file name with text (0 to return):
text4.txt
Text loaded. Total words: 141302
Max sentence length: 273
The second model has been successfully built!
```

Рис. 11. Загрузка второй модели

Пункт 5 меню - диалог моделей. Пользователь может выбрать порядок моделей, а так же ввести первое слово. Если введено более 1 слова - ошибка [Рис. 12]:

```
Current first model: loaded
Current second model: loaded
5
Select model order:
1. The main model starts first
2. The second model starts first
0. Return
1
Enter the initial word (0 to return):
she is
Error: Please enter exactly one word. Try again or enter 0 to return.
Enter the initial word (0 to return):
she
Enter the number of replicas (0 to return):
3

START OF DIALOGUE
Starting word: she
Model 1: she had declared at first that she could
Model 2: she could see that an encounter with the newcomer would do him
Model 1: him too much about his own work of propaganda for he
DIALOGUE ENDED
```

Рис. 12. Диалог

В любом подпункте меню можно выйти в меню вводом нуля [Рис. 13]:

```
Current first model: not loaded
Current second model: not loaded
1

Loading or building main model
1. Build from a text file
2. Load from model file
0. Return
0
```

Рис. 13. Выход из подпунктов

Завершение программы происходит по вводу нуля в основном меню [Рис. 14]:

```
0
Exit...
PS C:\M...
```

Рис. 14. Выход из приложения

Пользователь видит сообщение «Exit...».

## 6 Заключение

В ходе работы был успешно разработан программный модуль синтаксического анализатора и генератора текста на основе N-граммных моделей для автоматической обработки текстовых данных и генерации текстовых продолжений с учетом вероятностных характеристик исходного текста и интерактивную среду для генерации текста и диалога между двумя различными текстовыми моделями.

1. Разработан синтаксический анализатор текстовых файлов, осуществляющий разбиение текста на предложения по стандартным знакам препинания, выделение слов, состоящих только из буквенных символов, очистку текста от некорректных символов и цифр.

2. Реализовано построение N-граммной модели ( $N=4$ ) на основе проанализированного текста.

3. Создан генератор текста, обеспечивающий обработку пользовательского запроса, генерацию продолжения с учетом вероятностной модели, случайное определение длины предложения в пределах максимальной длины исходных предложений.

4. Реализован механизм диалога между двумя различными N-граммными моделями, где каждая модель генерирует реплику на основе последних слов оппонента.

5. Разработано взаимодействие пользователя с программой.

6. Обеспечено корректную обработку ошибок и некорректного ввода.

7. Разработан тестовый набор данных для проверки и протестировать.

Всего на работу было потрачено около 25 часов времени.

Работа выполнена на языке Haskell в среде программирования Visual Studio Code.

## Список использованной литературы

- [illegible]

# Приложение. Часть 1. Полный код программы

Листинг 30. Часть 1. Полный код программы

```
1 module Main (main) where
2
3 import Ladder — логика поиска цепочек
4 import System.Environment — для работы с аргументами командной
   строки
5
6 printHelpText :: String -> IO () — вывод справки
7 printHelpText msg = do
8   putStrLn (msg ++ "\n")
9   progName <- getProgName —принимает сообщение об ошибке
10  putStrLn ("Usage: " ++ progName ++ " <filename> <start> <end>"
   ) — сообщение и имя программы с форматом использования
11
12 main :: IO () — основная функция программы
13 main = do
14   args <- getArgs —получаем аргументы командной строки
15   case args of
16     [dictFile, start, end] -> do — три аргумента тогда
17       dict <- readDictionary dictFile —читаем словарь
18       case ladderSolve dict start end of —ищем решения
19         Nothing -> putStrLn "No solution" —нет решения(
20         Just sol -> do —тут выводим уже результат
21           print sol
22           putStrLn $ "Length: " ++ show (length sol)
23       _ -> printHelpText "Wrong number of arguments!"
24
25
26 {-# LANGUAGE ScopedTypeVariables #-}
27
28 module Graph
29   ( DiGraph ,
30     empty ,
31     addNode ,
32     addEdge ,
33     addEdges ,
34     buildDiGraph ,
35     children ,
36     deleteNode ,
37     deleteNodes ,
38     deleteEdge ,
39     SearchState ,
40     SearchResult (..) ,
41     bfsSearch ,
```

```

42     BiSearchState ,
43     biBfsSearch ,
44 )
45 where
46
47 import qualified Data.HashMap.Lazy as M
48 import Data.Hashable (Hashable)
49 import qualified Data.List as L
50 import Data.Maybe (isJust)
51
52 type DiGraph a = M.HashMap a [a] —тип — отображения из вершины
    с список смежных вершин
53
54 — создание пустого графа
55 empty :: DiGraph a
56 empty = M.empty
57
58 —добавление вершины
59 addNode :: (Hashable a, Eq a) => a -> DiGraph a -> DiGraph a
60 addNode =
61     M.alter
62     ( \mNodes ->
63         case mNodes of
64             Nothing -> Just [] — если нет вершины, то с пустым сп
65                 иском смежности
66             value -> value
67     )
68
69 —добавление ориентированного ребра, убирает дубликаты в списке
    смежности
70 addEdge :: (Hashable a, Eq a) => (a, a) -> DiGraph a -> DiGraph
    a
71 addEdge (node, child) = M.alter insertEdge node —M.alter для из
    менения значения, связанного с ключом node в HashMap
72 where
73     insertEdge Nothing = Just [child] —узел node не существует
74         в графе — создаем новый список смежности, содержащий толь
75         ко child
76     insertEdge (Just nodes) = —узел существует — добавляем
77         child в начало списка nodes и убираем дубликаты с помощью
78         L.nub
79     Just (L.nub (child : nodes))
80
81 —принимает список ребер и граф, возвращает граф с добавленными
    ребрами
82 addEdges :: (Hashable a, Eq a) => [(a, a)] -> DiGraph a ->
    DiGraph a

```

```

78 addEdges [] graph = graph —список ребер пуст, возвращаем исходн
    ый граф
79 addEdges (edge : edges) graph = addEdge edge (addEdges edges
    graph) —есть ребро и хвост списка, то добавляем текущее ребр
    о edge к графу, полученному рекурсивным вызовом addEdges для
    хвоста edges и исходного графа
80
81 buildDiGraph :: (Hashable a, Eq a) => [(a, [a])] -> DiGraph a
82 buildDiGraph nodes = go nodes M.empty
83   where
84     go [] graph = graph —список пуст, возвращаем граф
85     go ((key, value) : xs) graph = M.insert key value (go xs
    graph) —вставляем в граф ключ key со значением value (сп
    исок смежных вершин) и рекурсивно обрабатываем хвост.
86
87 —принимает вершину и граф, возвращает список дочерних вершин
88 children :: (Hashable a, Eq a) => a -> DiGraph a -> [a]
89 children = M.findWithDefault []
90
91 —удаление вершины
92 deleteNode :: (Hashable a, Eq a) => a -> DiGraph a -> DiGraph a
93 deleteNode = M.delete
94
95 —удаление списка вершин
96 deleteNodes :: (Hashable a, Eq a) => [a] -> DiGraph a -> DiGraph
    a
97 deleteNodes [] graph = graph —список пуст, возвращаем граф
98 deleteNodes (x : xs) graph = M.delete x (deleteNodes xs graph)
    —удаляем вершину x из графа, полученного рекурсивным удалени
    ем хвоста xs
99
100 —удаление ребер
101 deleteEdge :: (Hashable a, Eq a) => (a, a) -> DiGraph a ->
    DiGraph a
102 deleteEdge (node, child) =
103   M.alter —для изменения значения по ключу node
104   ( \mNodes ->
105     case mNodes of
106       Nothing -> Just [] —если узел не найден, то возвращае
    м пустой список
107       Just nodes ->
108         Just (L.delete child nodes) —узел найден, то удаляе
    м child из списка смежности с помощью L.delete
109     )
110   node
111
112 —тип состояния: текущий фронт (очередь) вершин, граф оставшихся
    вершин и граф предшествования.

```



```

113 type SearchState a = ([a], DiGraph a, DiGraph a)
114 —тип результат поиска либо неудача, либо успех с графом предше-
    твования
115 data SearchResult a = Unsuccessful | Successful (DiGraph a)
116
117 —поиск в ширину от начальной до конечной вершины
118 bfsSearch :: forall a. (Hashable a, Eq a) => DiGraph a -> a -> a
    -> Maybe [a]
119 bfsSearch graph start end
120   | start == end = Just [start] —начальная и конечная вершины с
    овпадают, возвращаем список из одной вершины
121   | otherwise = —запускаем вспомогательную функцию bfsSearch' с
    начальным состоянием: фронт из start, исходный граф и пуст
    ой граф предшествования
122     case bfsSearch' ([start], graph, empty) of
123       Successful preds -> Just (findSolution preds) —успех то
    гда восстанавливаем путь с помощью findSolution
124       Unsuccessful -> Nothing —возвращаем Nothing
125 where —восстанавливает путь от end до start по графу предшест-
    вования g
126 findSolution :: DiGraph a -> [a]
127 findSolution g = L.reverse (go end) —переворачиваем
128 where
129   go x =
130     case children x g of —смотрим на предшественников
131       [] -> [x] — предшественников нет то есть x дб начал
    ьной вершиной
132       (v : _) -> x : go v — иначе первый предшественник v
    . добавляем x к пути от v
133
134 addMultiplePredecessors :: [(a, [a])] -> DiGraph a ->
    DiGraph a
135 addMultiplePredecessors [] g = g —список пуст, возвращаем g
    раф
136 addMultiplePredecessors ((n, ch) : xs) g = —обрабатываем хв
    ост
137   addMultiplePredecessors xs (go n ch g)
138 where
139   go n [] g = g — список детей пуст тогда граф
140   go n (x : xs) g = go n xs (addEdge (x, n) g) —для каждо
    го ребенка x из ch добавляем ребро (x, n) в граф пред-
    шествования
141
142 —один шаг bfs
143 bfsSearch' :: SearchState a -> SearchResult a
144 bfsSearch' ([], _, preds) = Unsuccessful —фронт пусть тогда
    неудача

```

```

145 bfsSearch' (frontier, g, preds) = —иначе рабиваем на 3 част
    и
146 let g' = deleteNodes frontier g —удаляем вершины фронта
147     ch = — список пар (n, [дети, которые в g'])
148     L.map
149         (\n -> (n, L.filter ('M.member' g') (children n g)
150             ))
151     frontier
152     frontier' = L.concatMap snd ch —объединение всех таки
        x детей
153     preds' = addMultiplePredecessors ch preds —обновляем
        граф предшествования
154 in if end 'L.elem' frontier'
155     then Successful preds' —если конечная вершина в нов
        ом фронте то возвращаем успех
156     else bfsSearch' (frontier', g', preds')—иначе рекур
        сивно вызываем bfsSearch' с новым состоянием
157
158 type BiSearchState a = (SearchState a, SearchState a)
159 —двунаправленный поиск в ширину — одновременно из начальной и к
    онечной вершины(прямой и обратный поиск)
160 biBfsSearch :: forall a. (Hashable a, Eq a) => DiGraph a -> a ->
    a -> Maybe [a]
161 biBfsSearch graph start end
162 | start == end = Just [start] —начальная и конечная вершины с
    овпадают
163 | otherwise = —начальное состояние для прямого поиска (fState
    ) и обратного (bState)
164 let fState = ([start], graph, empty)
165     bState = ([end], graph, empty)
166 in biBfsSearch' (fState, bState)
167 where
168     findSolution :: DiGraph a -> a -> [a]
169     findSolution g = go
170     where
171         go x =
172             case children x g of
173             [] -> [x] —предшественников нет
174             (v : _) -> x : go v — иначе первый предшественник
                v. добавляем x к пути от v
175 —проверяет, есть ли пересечение между фронтами прямого и обрат
    ного поиска
176 checkOverlap :: BiSearchState a -> Maybe [a]
177 checkOverlap ((fFrontier', _, fPreds'), (bFrontier', _,
    bPreds')) =
178 let getSolution x =
179     let fPath = findSolution fPreds' x —путь от start д
        о x

```

```

179         bPath = findSolution bPreds' x —путь от x до
           end
180         in L.reverse fPath ++ L.tail bPath —объединяем раз
           вернутый fPath и bPath без первого элемента (это
           x)
181     overlaps = —вершины из фронта прямого поиска, которые
           есть в графе предшествования обратного поиска
182     L.filter ('M.member' bPreds') fFrontier'
183     solutions = —список всех возможных путей, отсортирова
           нный по длине
184     L.sortOn L.length (L.map getSolution overlaps)
185     in if L.null solutions
186         then Nothing —если нет решений
187         else Just $ L.head solutions — иначе кратчайший пут
           ь
188 —проверяет, находится ли node во фронте frontier
189     checkSolution :: SearchState a -> a -> Maybe [a]
190     checkSolution (frontier, _, preds) node
191         | node 'L.elem' frontier = Just (findSolution preds node)
           —путь от node до начальной вершины этого направления
192         | otherwise = Nothing
193
194     biBfsSearch' :: BiSearchState a -> Maybe [a]
195     biBfsSearch' state@(fState@(fFrontier, _, _), bState@(
           bFrontier, _, _)) —принимает состояние state (прямое и о
           братное)
196         | L.null fFrontier && L.null bFrontier = Nothing —оба пус
           ты
197         | isJust fSol = fmap L.reverse fSol —в прямом поиске коне
           чная вершина достигнута (fSol это Just), то возвращ
           аем развернутый путь
198         | isJust bSol = bSol —Если в обратном поиске начальная ве
           ршина достигнута (bSol это Just), возвращаем путь
199         | isJust overlapSol = overlapSol —Если есть пересечение,
           возвращаем решение из overlapSol
200         | otherwise = biBfsSearch' biState' —обновляем состояния
           fState' и bState' с помощью bfsSearchStep и рекурсивно
           вызываем biBfsSearch' с новым состоянием
201     where
202         fSol = checkSolution fState end
203         bSol = checkSolution bState start
204         overlapSol = checkOverlap state
205         fState' = bfsSearchStep fState
206         bState' = bfsSearchStep bState
207         biState' = (fState', bState')
208
209 —аналогично функции в bfsSearch, добавляет несколько ребер в гр
           аф предшествования

```

```

210     addMultiplePredecessors :: [(a, [a])] -> DiGraph a ->
        DiGraph a
211     addMultiplePredecessors [] g = g
212     addMultiplePredecessors ((n, ch) : xs) g =
213         addMultiplePredecessors xs (go n ch g)
214     where
215         go n [] g = g
216         go n (x : xs) g = go n xs (addEdge (x, n) g)
217 —Выполняет один шаг BFS: обновляет граф, вычисляет новых детей
    и новый фронт, обновляет граф предшествования.
218     bfsSearchStep :: SearchState a -> SearchState a
219     bfsSearchStep (frontier, g, preds) =
220         let g' = deleteNodes frontier g
221             ch =
222                 L.map
223                     (\n -> (n, L.filter ('M.member' g') (children n g)
224                     ))
225                     frontier
226             frontier' = L.concatMap snd ch
227             preds' = addMultiplePredecessors ch preds
228         in (frontier', g', preds')
229
230 — логика поиска цепочек
231 module Ladder
232     ( Dictionary,
233       readDictionary,
234       ladderSolve,
235     )
236 where
237
238 import qualified Data.ByteString as BS
239 import qualified Data.ByteString.Char8 as C
240 import qualified Data.List as L
241 import qualified Graph as G
242 import qualified PermutationMap as PM
243
244 —тип словаря как списка байтовых строк
245 type Dictionary = [BS.ByteString]
246
247 —чтение словаря из файла, фильтрация только букв a-z
248 readDictionary :: FilePath -> IO Dictionary
249 readDictionary filepath = do
250     dictionaryContent <- C.readFile filepath —читаем словарь из ф
        айла
251     let lines = C.lines dictionaryContent —чтение всего содержи-
        мо файла как байтовой строки

```

```

252     words = L.map (C.filter ('L.elem' ['a' .. 'z'])) lines —р
        азбиение на строки, фильтриция только букв а–z
253     return words —возврат отчищенного списка
254
255 —удаление первого вхождения символа из строки
256 delete :: Char → BS.ByteString → BS.ByteString
257 delete ch string = case C.uncons string of
258     Just (x, xs) → if ch == x then xs else C.cons x (delete ch xs
        ) —если символ совпадает — возвращаем хвост, иначе рекурси
        вно обрабатываем остаток
259     Nothing → C.empty —пустая строка базовый случай
260
261 —вычисление соседних слов
262 computeCandidates :: PM.PermutationMap → BS.ByteString → [BS.
    ByteString]
263 computeCandidates map word = —мэп — карта перестановок
264     let candidates = modified ++ removed ++ added ++ [word] —спис
        ок всех возможных кандидатов—мутаций
265         perms = —для каждого кандидата ищем в карте перестановок
            реальные слова из словаря
266             L.concatMap
267                 (\x → PM.findWithDefault [] x map)
268                 candidates
269         in L.filter (/= word) (L.nub perms) —фильтруем убираем дубли
            каты
270     where
271         added = [C.cons x word | x <- ['a' .. 'z']] — добавление бу
            квы в начало
272         removed = [delete x word | x <- C.unpack word] — удаление о
            дной буквы
273         modified = [C.cons x (delete y word) | x <- ['a' .. 'z'], y
            <- C.unpack word, x /= y] —замена каждой буквы
274
275 —граф из словаря
276 mkLadderGraph :: Dictionary → G.DiGraph BS.ByteString
277 mkLadderGraph dict = G.buildDiGraph nodes —построение графа из
        списка (слово, список соседей)
278     where
279         map = PM.createPermutationMap dict —карта перестановок для
            эффективного поиска соседей
280         nodes = —для каждого слова вычисляем его соседей
281             L.map (\w → (w, computeCandidates map w)) dict
282
283 —строит граф и ищет путь двунаправленным поиском
284 ladderSolve :: Dictionary → String → String → Maybe [BS.
    ByteString]
285 ladderSolve dict start end = —Строим граф словной цепочки

```

```

286 let g = mkLadderGraph dict —двунаправленный поиск в ширину, п
    преобразуя String в ByteString
287 in G.biBfsSearch g (C.pack start) (C.pack end)
288
289
290 module PermutationMap
291 ( PermutationMap ,
292   empty ,
293   member ,
294   alter ,
295   delete ,
296   insert ,
297   lookup ,
298   findWithDefault ,
299   createPermutationMap ,
300 )
301 where
302
303 import qualified Data.ByteString as BS
304 import qualified Data.HashMap.Lazy as M
305 import Data.Maybe (fromMaybe)
306 import Prelude hiding (lookup)
307
308 —тип для отображения отсортированных версий слов на списки исхо
    дных слов
309 type PermutationMap = M.HashMap BS.ByteString [BS.ByteString] —
    ключ — отсортированная версия слова, значение — список исходн
    ых слов с такими же буквами
310
311 empty :: PermutationMap
312 empty = M.empty —Создание пустой карты перестановок
313
314 member :: BS.ByteString -> PermutationMap -> Bool
315 member key = M.member (BS.sort key) —Проверка наличия ключа в к
    арте
316
317
318 alter :: —alter для модификации значения по ключу
    ( Maybe [BS.ByteString] ->
      Maybe [BS.ByteString]
    ) ->
    BS.ByteString ->
    PermutationMap ->
    PermutationMap
319
320
321 alter f key = M.alter f (BS.sort key) —применяем переданную фун
    кцию f к отсортированной версии ключа
322
323
324 delete :: BS.ByteString -> PermutationMap -> PermutationMap

```

```

328 delete key = M.delete (BS.sort key) —удаление записи по ключу (
    отсортированной версии слова)
329
330 insert :: BS.ByteString -> [BS.ByteString] -> PermutationMap ->
    PermutationMap
331 insert key = M.insert (BS.sort key) —вставка значения по отсортированному ключу
332
333 lookup :: BS.ByteString -> PermutationMap -> Maybe [BS.
    ByteString]
334 lookup key = M.lookup (BS.sort key) —поиск значения по отсортированному ключу, возвращает Maybe
335
336 findWithDefault :: —поиск со значением по умолчанию
    [BS.ByteString] ->
337     BS.ByteString ->
338     PermutationMap ->
339     [BS.ByteString]
340
341 findWithDefault defaultValue key map =
342     fromMaybe [] (PermutationMap.lookup key map) —Если lookup возвращает Nothing, используем пустой список
343
344 —создание карты перестановок из списка слов
345 createPermutationMap :: [BS.ByteString] -> PermutationMap
346 createPermutationMap = go empty —запуск рекурсивной функции с пустой картой
347     where
348         go permMap [] = permMap
349         go permMap (x : xs) = go (insertPermutation x permMap) xs —рекурсивная обработка списка слов
350
351         insertPermutation word = alter (insertList word) word —функция для вставки одного слова в карту
352
353         insertList word Nothing = Just [word] —ключа нет, создаем новый список с одним словом
354         insertList word (Just words) = Just $ word : words —ключ уже есть, добавляем слово в существующий список

```

## Приложение. Часть 2. Полный код программы

Листинг 31. Часть 2. Полный код программы

```
1 {-# LANGUAGE OverloadedStrings #-}
2
3 module Main where
4
5 import System.IO
6 import Control.Exception (catch, IOException)
7 import Control.Monad (forever, when)
8 import Data.List (isSuffixOf)
9 import Text.Read (readMaybe)
10 import System.Random (randomRIO)
11 import Control.Concurrent (threadDelay)
12 import Lib
13 import Data.Text (Text)
14 import qualified Data.Text as T
15 import qualified Data.Text.IO as TIO
16
17 data ModelWithInfo = ModelWithInfo {
18     model :: NGramModel,
19     maxSentenceLength :: Int
20 } deriving (Show)
21
22 main :: IO ()
23 main = do
24     TIO.putStrLn "\n 4-GRAM TEXT GENERATOR"
25     mainLoop Nothing Nothing
26
27 mainLoop :: Maybe ModelWithInfo -> Maybe ModelWithInfo -> IO ()
28 mainLoop currentModel model2 = do
29     TIO.putStrLn "\n MENU"
30     TIO.putStrLn "0. Exit"
31     TIO.putStrLn "1. Load or build main model"
32     TIO.putStrLn "2. Save the current model to file"
33     TIO.putStrLn "3. Generate the continuation of the sentence"
34     TIO.putStrLn "4. Load or build second model for the dialogue"
35     TIO.putStrLn "5. Dialogue between two models"
36
37     — Отображение текущих моделей
38     TIO.putStrLn $ T.pack $ "\n Current first model: " ++
39         modelStatus currentModel
40     TIO.putStrLn $ T.pack $ "Current second model: " ++
41         modelStatus model2
```



```

41 choice <- TIO.getLine
42 case T.unpack choice of
43
44     "1" -> do
45         TIO.putStrLn "\n Loading or building main model"
46         TIO.putStrLn "1. Build from a text file "
47         TIO.putStrLn "2. Load from model file "
48         TIO.putStrLn "0. Return "
49         subChoice <- TIO.getLine
50         case T.unpack subChoice of
51             "0" -> mainLoop currentModel model2
52             "1" -> do
53                 loadTextModelLoop currentModel model2
54             "2" -> do
55                 loadModelLoop currentModel model2
56             _ -> do
57                 TIO.putStrLn "Wrong choice!"
58                 mainLoop currentModel model2
59
60     "2" -> do
61         case currentModel of
62             Nothing -> do
63                 TIO.putStrLn "Build or download the model
64                     first!"
65                 mainLoop currentModel model2
66             Just modelInfo -> do
67                 TIO.putStrLn "Enter a file name to save (0
68                     to return):"
69                 fileName <- TIO.getLine
70                 when (fileName /= "0") $ do
71                     saveModel (T.unpack fileName) (model
72                         modelInfo)
73                     TIO.putStrLn "Model saved!"
74                     mainLoop currentModel model2
75                 when (fileName == "0") $ mainLoop
76                     currentModel model2
77
78     "3" -> do
79         case currentModel of
80             Nothing -> do
81                 TIO.putStrLn "Build or download the model
82                     first!"
83                 mainLoop currentModel model2
84             Just modelInfo -> do
85                 TIO.putStrLn "Enter starting words (1-3
86                     words, 0 to return):"
87                 input <- TIO.getLine
88                 when (input /= "0") $ do

```

```

83 let wordsList = map T.toLowerCase (T.words
84     input)
85 if length wordsList >= 1 && length
86     wordsList <= 3
87     then do
88         let initialLen = length
89             wordsList
90         let maxTotalLen =
91             maxSentenceLength modelInfo
92
93         if maxTotalLen <= initialLen
94             then do
95                 TIO.putStrLn $ T.pack $
96                     "Initial words
97                     already have " ++
98                     show initialLen ++
99                     " words, but maximum
100                     sentence length
101                     is " ++ show
102                     maxTotalLen ++
103                     ". Cannot generate
104                     continuation."
105                 mainLoop currentModel
106                     model2
107             else do
108                 — Генерируем случайную
109                     длину для дополнитель-
110                     ных слов
111                 — Минимум 1 дополнитель-
112                     ное слово, максимум —
113                     оставшееся место
114                 let maxAdditional =
115                     maxTotalLen -
116                     initialLen
117                 randomAdditionalLen <-
118                     if maxAdditional > 0
119                         then randomRIO (1,
120                             maxAdditional)
121                         else return 0
122
123                 if randomAdditionalLen
124                     <= 0
125                     then do
126                         TIO.putStrLn "
127                             Cannot
128                             generate
129                             continuation
130                             — no space

```

```

106         for
107             additional
108             words."
109         mainLoop
110             currentModel
111             model2
112         else do
113             result <-generateContinuation (model
114             modelInfo) wordsList
115             randomAdditionalLen
116             let totalLength
117                 = length
118                 result
119             TIO.putStrLn $ "
120             Generated
121             continuation:
122             " 'T.append'
123             T.unwords
124             result
125             mainLoop
126             currentModel
127             model2
128         else do
129             TIO.putStrLn "Error: Please
130             enter between 1 and 3 words."
131             mainLoop currentModel model2
132             when (input == "0") $ mainLoop currentModel
133             model2
134
135 "4" -> do
136     TIO.putStrLn "\n Loading the second model"
137     TIO.putStrLn "1. Build from a text file"
138     TIO.putStrLn "2. Load from model file"
139     TIO.putStrLn "0. Return"
140     subChoice <- TIO.getLine
141     case T.unpack subChoice of
142         "0" -> mainLoop currentModel model2
143         "1" -> do
144             loadTextModelForSecondLoop currentModel
145             model2
146         "2" -> do
147             loadSecondModelLoop currentModel model2
148         _ -> do
149             TIO.putStrLn "Wrong choice!"
150             mainLoop currentModel model2
151
152 "5" -> do
153     case (currentModel , model2) of

```

```

135         (Just m1, Just m2) -> do
136             TIO.putStrLn "Select model order: "
137             TIO.putStrLn "1. The main model starts first
138             "
139             TIO.putStrLn "2. The second model starts
140             first"
141             TIO.putStrLn "0. Return"
142             orderChoice <- TIO.getLine
143             case T.unpack orderChoice of
144                 "0" -> mainLoop currentModel model2
145                 "1" -> startDialogLoop (model m1) (model
146                     m2) currentModel model2
147                 "2" -> startDialogLoop (model m2) (model
148                     m1) currentModel model2
149                 _ -> do
150                     TIO.putStrLn "Wrong choice!"
151                     mainLoop currentModel model2
152             _ -> do
153                 TIO.putStrLn "First , download both models! (
154                     the main and the second)"
155                 mainLoop currentModel model2
156
157     "0" -> TIO.putStrLn "Exit ..."
158     _ -> do
159         TIO.putStrLn "Wrong choice!"
160         mainLoop currentModel model2
161
162 — Вспомогательная функция для статуса модели
163 modelStatus :: Maybe ModelWithInfo -> String
164 modelStatus Nothing = "not loaded"
165 modelStatus (Just _) = "loaded"
166
167 — Функция для запуска диалога
168 startDialogLoop :: NGramModel -> NGramModel -> Maybe
169     ModelWithInfo -> Maybe ModelWithInfo -> IO ()
170 startDialogLoop firstModel secondModel currentModel model2 = do
171     TIO.putStrLn "Enter the initial word (0 to return):"
172     startWord <- TIO.getLine
173     case startWord of
174         "0" -> mainLoop currentModel model2
175         _ -> do
176             let wordsList = T.words startWord
177             if length wordsList /= 1
178             then do
179                 TIO.putStrLn "Error: Please enter exactly
180                     one word. Try again or enter 0 to return.
181                     "

```

```

174         startDialogLoop firstModel secondModel
           currentModel model2
175     else do
176         TIO.putStrLn "Enter the number of replicas
           (0 to return):"
177         repsStr <- TIO.getLine
178         case repsStr of
179             "0" -> mainLoop currentModel model2
180             _ -> do
181                 let reps = safeRead (T.unpack
           repsStr) 5
182                 startDialog firstModel secondModel
           wordsList reps
183                 mainLoop currentModel model2
184
185 — Цикл загрузки модели из файла с повторением при ошибке
186 loadModelLoop :: Maybe ModelWithInfo -> Maybe ModelWithInfo ->
           IO ()
187 loadModelLoop currentModel model2 = do
188     TIO.putStrLn "Enter the file name of the model (0 to return)
           : "
189     fileName <- TIO.getLine
190     case fileName of
191         "0" -> mainLoop currentModel model2
192         _ -> do
193             loadedModel <- loadModel (T.unpack fileName)
194             case loadedModel of
195                 Just m -> do
196                     TIO.putStrLn "Model loaded!"
197                     mainLoop (Just $ ModelWithInfo m 20) model2
198                 Nothing -> do
199                     TIO.putStrLn "Model loading error! Please
           try again."
200                     loadModelLoop currentModel model2
201
202 — Цикл загрузки текстовой модели
203 loadTextModelLoop :: Maybe ModelWithInfo -> Maybe ModelWithInfo
           -> IO ()
204 loadTextModelLoop currentModel model2 = do
205     TIO.putStrLn "Enter a file name with text (0 to return):"
206     fileName <- TIO.getLine
207     case fileName of
208         "0" -> mainLoop currentModel model2
209         _ -> do
210             result <- readFileSafe (T.unpack fileName)
211             case result of
212                 Left errorMsg -> do
213                     TIO.putStrLn $ T.pack errorMsg

```

```

214         loadTextModelLoop currentModel model2
215     Right content -> do
216         let sentences = splitText (T.pack content)
217         — Подсчет и вывод количества слов и максима
           льной длины предложения
218         let wordCount = sum (map length sentences)
219         let maxSentenceLen = if null sentences then
           0 else maximum (map length sentences)
220         TIO.putStrLn $ "Text loaded. Total words: "
           'T.append' T.pack (show wordCount)
221         TIO.putStrLn $ "Max sentence length: " 'T.
           append' T.pack (show maxSentenceLen)
222         let newModel = buildNGramModel sentences 4
223         TIO.putStrLn "Model successfully built!"
224         — Сохраняем модель и максимальную длину пре
           дложения
225         mainLoop (Just $ ModelWithInfo newModel
           maxSentenceLen) model2
226
227 — Цикл загрузки второй модели из текстового файла
228 loadTextModelForSecondLoop :: Maybe ModelWithInfo -> Maybe
           ModelWithInfo -> IO ()
229 loadTextModelForSecondLoop currentModel model2 = do
230     TIO.putStrLn "Enter a file name with text (0 to return): "
231     fileName <- TIO.getLine
232     case fileName of
233         "0" -> mainLoop currentModel model2
234     _ -> do
235         result <- readFileSafe (T.unpack fileName)
236         case result of
237             Left errorMsg -> do
238                 TIO.putStrLn $ T.pack errorMsg
239                 loadTextModelForSecondLoop currentModel
                   model2
240             Right content -> do
241                 let sentences = splitText (T.pack content)
242                 — Подсчет и вывод количества слов и максима
                   льной длины
243                 let wordCount = sum (map length sentences)
244                 let maxSentenceLen = if null sentences then
                   0 else maximum (map length sentences)
245                 TIO.putStrLn $ "Text loaded. Total words: "
                   'T.append' T.pack (show wordCount)
246                 TIO.putStrLn $ "Max sentence length: " 'T.
                   append' T.pack (show maxSentenceLen)
247                 let newModel = buildNGramModel sentences 4
248                 TIO.putStrLn "The second model has been
                   successfully built!"

```

```

249         mainLoop currentModel (Just $ ModelWithInfo
250             newModel maxSentenceLen)
251 — Цикл загрузки второй модели из файла модели
252 loadSecondModelLoop :: Maybe ModelWithInfo -> Maybe
253     ModelWithInfo -> IO ()
254 loadSecondModelLoop currentModel model2 = do
255     TIO.putStrLn "Enter the file name of the model (0 to return)
256     : "
257     fileName <- TIO.getLine
258     case fileName of
259     "0" -> mainLoop currentModel model2
260     _ -> do
261         loadedModel <- loadModel (T.unpack fileName)
262         case loadedModel of
263         Just m -> do
264             TIO.putStrLn "The second model has been
265             loaded!"
266             — Для загруженных моделей устанавливаем деф
267             олтную максимальную длину
268             mainLoop currentModel (Just $ ModelWithInfo
269             m 20)
270         Nothing -> do
271             TIO.putStrLn "Model loading error! Please
272             try again."
273             loadSecondModelLoop currentModel model2
274
275 startDialog :: NGramModel -> NGramModel -> [Text] -> Int -> IO
276     ()
277 startDialog model1 model2 startWords reps = do
278     TIO.putStrLn "\n START OF DIALOGUE"
279     TIO.putStrLn $ "Starting word: " 'T.append' T.unwords
280     startWords
281     dialogLoop model1 model2 startWords reps 0
282
283 dialogLoop :: NGramModel -> NGramModel -> [Text] -> Int -> Int
284     -> IO ()
285 dialogLoop _ _ _ totalReps currentRep
286     | currentRep >= totalReps = TIO.putStrLn "DIALOGUE ENDED"
287 dialogLoop model1 model2 lastPhrase totalReps currentRep = do
288     let currentModel = if even currentRep then model1 else
289     model2
290     let opponentModel = if even currentRep then model2 else
291     model1
292     let speaker = if even currentRep then "Model 1" else "Model
293     2"
294
295     response <- generateResponse currentModel lastPhrase

```

```

284 TIO.putStrLn $ T.pack speaker 'T.append' ": " 'T.append' T.
    unwords response
285
286 dialogLoop model1 model2 response totalReps (currentRep + 1)
287
288 generateResponse :: NGramModel -> [Text] -> IO [Text]
289 generateResponse model phrase = do
290   — Получаем возможные ключи в правильном порядке: 3 слова ->
    2 слова -> 1 слово
291   let possibleKeys = getPossibleKeys phrase
292
293   — Пытаемся найти валидный ключ в порядке убывания длины
294   case findValidKey model possibleKeys of
295     Just key -> do
296       maxlen <- randomRIO (3, 15)
297       result <- generateContinuation model key maxlen
298       return result
299
300     Nothing -> do
301       — Генерация случайного предложения
302       allKeys <- getRandomKey model
303       case allKeys of
304         Just randomKey -> do
305           maxlen <- randomRIO (3, 10)
306           result <- generateContinuation model
    randomKey maxlen
307           return ("!" : result) — Помечаем случайное
    предложение
308         Nothing -> return ["..."] — Если совсем нет кл
    ючей
309
310 — Безопасное чтение файла с обработкой ошибок
311 readFileSafe :: FilePath -> IO (Either String String)
312 readFileSafe fileName = catch (readFile fileName >>= return .
    Right) handleError
313 where
314   handleError :: IOException -> IO (Either String String)
315   handleError e = do
316     let errorMsg = "File reading error: " ++ show e
317     return $ Left errorMsg
318
319 — Безопасное чтение чисел с значением по умолчанию
320 safeRead :: String -> Int -> Int
321 safeRead str defaultValue = case readMaybe str of
322   Just n -> n
323   Nothing -> defaultValue
324
325 {-# LANGUAGE OverloadedStrings #-}

```



```

326
327 module Lib (
328     NGramModel,
329     splitText ,
330     buildNGramModel ,
331     saveModel ,
332     loadModel ,
333     generateContinuation ,
334     getPossibleKeys ,
335     findValidKey ,
336     getRandomKey ,
337     preprocessText
338 ) where
339
340 import Data.Char (isLetter , toLower , isPunctuation , isSpace ,
    isAscii)
341 import Data.Hashable (Hashable)
342 import Data.HashMap.Strict (HashMap)
343 import qualified Data.HashMap.Strict as HashMap
344 import Data.List (tails , sortOn)
345 import Data.Text (Text)
346 import qualified Data.Text as T
347 import qualified Data.Text.IO as TIO
348 import System.Random (randomRIO , getStdGen , randomR , StdGen ,
    newStdGen)
349 import System.IO
350 import Data.Maybe (fromMaybe , listToMaybe , catMaybes)
351 import Control.Exception (try , SomeException)
352 import Text.Read (readMaybe)
353 import Data.Ord (Down(..))
354
355 type NGram = [Text]
356 type NGramModel = HashMap NGram [(NGram , Double)]
357
358 — Упрощенная очистка слова
359 cleanWord :: Text -> Text
360 cleanWord word =
361     let cleaned = T.toLower $ T.filter validChar word
362     in if isValidCleanedWord cleaned then cleaned else T.empty
363     where
364         validChar c = isAscii c && (isLetter c || c == '\'' || c ==
            '—')
365         isValidCleanedWord w = not (T.null w) && T.any isLetter w
366
367 — Проверка валидности слова
368 isValidWord :: Text -> Bool
369 isValidWord word =

```

```

370     not (T.null word) && T.all validChar word && T.any isLetter
      word
371 where
372     validChar c = isAscii c && (isLetter c || c == '\'' || c ==
      '—')
373
374 — Функция для проверки завершения предложения
375 isSentenceTerminator :: Char → Bool
376 isSentenceTerminator c = c `elem` ("!?" :: [Char])
377
378 — Оптимизированное разделение текста на предложения
379 splitText :: Text → [[Text]]
380 splitText text =
381     let preprocessed = preprocessText text
382         sentences = splitSentences preprocessed
383     in filter (not . null) $ map processSentence sentences
384 where
385     splitSentences :: Text → [Text]
386     splitSentences t
387     | T.null t = []
388     | otherwise =
389         let (sentence, rest) = T.break isSentenceTerminator
          t
390             (punctuation, rest') = T.span
          isSentenceTerminator rest
391         in if T.null sentence
392            then splitSentences rest'
393            else (cleanSentence sentence 'T.append' T.take 1
          punctuation) : splitSentences rest'
394
395 cleanSentence :: Text → Text
396 cleanSentence = removeEdgePunctuation . T.strip
397
398 removeEdgePunctuation :: Text → Text
399 removeEdgePunctuation s =
400     let startPunct :: Text
401         startPunct = " \"' '({{"
402         endPunct :: Text
403         endPunct = " \"' ')}"
404         removeStart = T.dropWhile ('T.elem' startPunct) s
405         removeEnd = T.reverse $ T.dropWhile ('T.elem'
          endPunct) (T.reverse removeStart)
406     in removeEnd
407
408 processSentence :: Text → [Text]
409 processSentence = filter isValidWord . map (T.toLower) . T.
      words . T.map normalizeChar
410

```

```

411     normalizeChar :: Char -> Char
412     normalizeChar c
413         | c `elem` (" ,;:\\"'''()[]{}`" :: String) = ' '
414         | isPunctuation c && c /= '\\' && c /= '-' = ' '
415         | otherwise = c
416
417 — Строгая проверка N-граммы
418 filterValidNGram :: (NGram, NGram) -> Bool
419 filterValidNGram (key, value) =
420     all isValidWord (key ++ value)
421
422 — Оптимизированное построение N-граммной модели
423 buildNGramModel :: [[Text]] -> Int -> NGramModel
424 buildNGramModel sentences n =
425     let validSentences = filter (all isValidWord) sentences
426         allNGrams = concatMap (getNGrams n) validSentences
427         grouped = HashMap.fromListWith (++) [(key, [(value, 1)])
428             | (key, value) <- allNGrams]
429     in HashMap.map calculateProbabilities grouped
430 where
431     getNGrams :: Int -> [Text] -> [(NGram, NGram)]
432     getNGrams n words =
433         [ (take k context, take (n - k) continuation)
434         | k <- [1..min 3 (length words)]
435         , (context, continuation) <- zip (tails words) (drop k (
436             tails words))
437         , length context >= k
438         , length continuation >= n - k
439         , length context + length continuation >= n
440         , filterValidNGram (take k context, take (n - k)
441             continuation)
442         ]
443
444     calculateProbabilities :: [(NGram, Int)] -> [(NGram, Double)]
445     calculateProbabilities pairs =
446         let total = fromIntegral $ sum (map snd pairs)
447         in [(ngram, fromIntegral count / total) | (ngram, count)
448             <- pairs]
449
450 — Предварительная обработка текста
451 preprocessText :: Text -> Text
452 preprocessText text =
453     let asciiOnly = T.filter isAscii text
454         cleaned = preserveWordHyphens asciiOnly
455     in T.unwords . T.words $ cleaned
456
457 — Сохраняет дефисы внутри слов

```

```

454 preserveWordHyphens :: Text -> Text
455 preserveWordHyphens = T.unwords . map processWord . T.words
456 where
457     processWord w
458         | T.all (== '-') w = T.empty
459         | isValidHyphens w = w
460         | otherwise = T.filter (\c -> c /= '-' || isLetter c) w
461
462     isValidHyphens word =
463         let parts = T.splitOn "-" word
464         in all (T.any isLetter) parts && length parts > 1
465
466 — Сохранение модели в файл
467 saveModel :: FilePath -> NGramModel -> IO ()
468 saveModel filePath model = withFile filePath WriteMode $ \h ->
469     mapM_ \(k, vs) -> TIO.hPutStrLn h $ T.pack (show k) 'T.
470         append' " => " 'T.append' T.pack (show vs)) (HashMap.
471             toList model)
472
473 — Загрузка модели из файла
474 loadModel :: FilePath -> IO (Maybe NGramModel)
475 loadModel filePath = do
476     result <- try (TIO.readFile filePath) :: IO (Either
477         SomeException Text)
478     case result of
479         Left _ -> return Nothing
480         Right content ->
481             let lines' = T.lines content
482             parsed = catMaybes $ map parseLine lines'
483             in return $ if null parsed then Nothing else Just (
484                 HashMap.fromList parsed)
485
486 where
487     parseLine :: Text -> Maybe (NGram, [(NGram, Double)])
488     parseLine line =
489         let (keyPart, valuePart) = T.break (== '=') line
490         in case T.uncons valuePart of
491             Just ('=', rest) ->
492                 case T.uncons rest of
493                     Just ('>', rest') ->
494                         case T.uncons rest' of
495                             Just (' ', valueStr) ->
496                                 case readMaybe (T.unpack (T.
497                                     strip keyPart)) of
498                                     Just key ->
499                                         case readMaybe (T.unpack
500                                             valueStr) of
501                                             Just values -> Just
502                                                 (key, values)

```

```

495                                     Nothing -> Nothing
496                                     Nothing -> Nothing
497                                     _ -> Nothing
498                                     _ -> Nothing
499                                     _ -> Nothing
500
501 — Оптимизированная генерация продолжения предложения
502 generateContinuation :: NGramModel -> [Text] -> Int -> IO [Text]
503 generateContinuation model startWords maxLength = do
504     gen <- newStdGen
505     return $ generateEfficient model startWords gen maxLength
506 where
507     generateEfficient :: NGramModel -> [Text] -> StdGen -> Int
508     -> [Text]
509     generateEfficient model currentWords gen maxLength =
510         generateLoop model currentWords gen maxLength
511         currentWords
512
513 generateLoop :: NGramModel -> [Text] -> StdGen -> Int -> [
514     Text] -> [Text]
515 generateLoop _ _ _ 0 acc = acc
516 generateLoop model currentWords gen remaining acc =
517     let possibleKeys = getPossibleKeys currentWords
518         key = findValidKey model possibleKeys
519     in case key of
520         Nothing -> acc
521         Just k ->
522             case HashMap.lookup k model of
523                 Nothing -> acc
524                 Just continuations ->
525                     let (choice, newGen) =
526                         efficientWeightedRandom continuations
527                         gen
528                     newWords = acc ++ choice
529                     newRemaining = remaining - length
530                     choice
531                     in if newRemaining <= 0
532                         then newWords
533                         else generateLoop model (currentWords
534                             ++ choice) newGen newRemaining
535                             newWords
536
537 — Эффективный взвешенный случайный выбор с предварительной
538     сортировкой
539 efficientWeightedRandom :: [(NGram, Double)] -> StdGen -> (
540     NGram, StdGen)
541 efficientWeightedRandom choices gen =
542     let total = sum (map snd choices)

```

```

533         (r, newGen) = randomR (0, total) gen
534         — Сортируем по убыванию вероятности для более быстрого выбора
535         sortedChoices = sortOn (Down . snd) choices
536         in pick sortedChoices r newGen
537     where
538         pick [] _ g = ([], g)
539         pick ((ngram, prob):rest) rVal g
540             | rVal <= prob = (ngram, g)
541             | otherwise = pick rest (rVal - prob) g
542
543 — Получение возможных ключей из фразы в правильном порядке
544 getPossibleKeys :: [Text] -> [[Text]]
545 getPossibleKeys words =
546     let n = length words
547         — Берем последние 1, 2, 3 слова в ПРЯМОМ порядке
548         key1 = if n >= 1 then [last words] else []
549         key2 = if n >= 2 then drop (n-2) words else []
550         key3 = if n >= 3 then drop (n-3) words else []
551     in filter (not . null) [key3, key2, key1] — Сначала проверяем самые длинные ключи
552
553 — Поиск валидного ключа в модели
554 findValidKey :: NGramModel -> [[Text]] -> Maybe [Text]
555 findValidKey model keys =
556     case filter ('HashMap.member' model) keys of
557         [] -> Nothing
558         (k:_) -> Just k
559
560 — Получение случайного ключа из модели
561 getRandomKey :: NGramModel -> IO (Maybe [Text])
562 getRandomKey model =
563     if HashMap.null model
564     then return Nothing
565     else do
566         let keys = HashMap.keys model
567         idx <- randomRIO (0, length keys - 1)
568         return $ Just (keys !! idx)

```